中国科学院大学
University of Chinese Academy of Sciences

I/O设备

中国科学院大学计算机学院

2025-12-08

输入和输出

- 数据需要传入及传出计算机系统 → 输入/输出设备（I/O设备）
- I/O设备
  - 输入设备、输出设备；键盘、鼠标、显示器、存储设备、网络设备、…
  - 大量的设备厂商，丰富的I/O设备
  - 计算机系统通过设备驱动和设备交互
  - 设备驱动运行于内核态，通常由第三方厂商开发。若有bug，常会引发宕机
- OS的目标
  - 提供一种通用的、方便的方法来访问各种I/O设备
  - 充分发挥I/O设备的性能

内容提要

- I/O 设备
  - 设备控制器与缓冲区
  - 寻址
- 数据传输
  - PIO, 中断, DMA
- 同步I/O与异步I/O
- 设备驱动

硬件回顾

- 计算硬件
  - CPU和片内缓存
  - 内存控制器和内存
  - I/O总线
  - I/O设备
- I/O硬件
  - I/O总线
  - I/O设备控制器或适配器
  - I/O设备

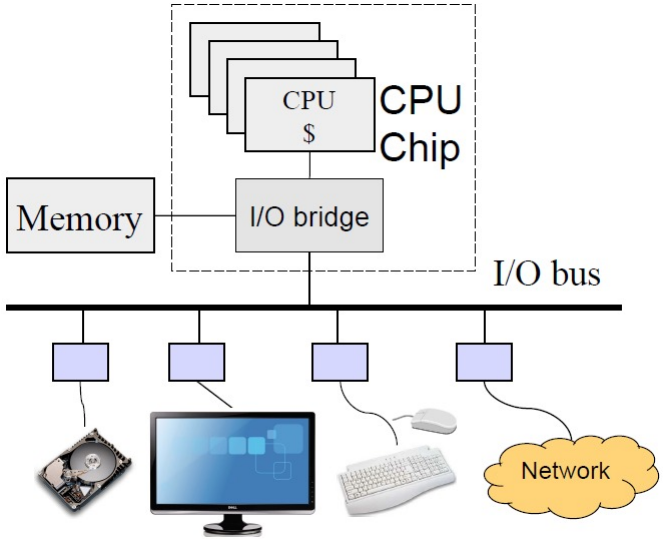

设备控制器（Controller/ Adaptor）

- 控制设备的部件
  - 解析主机发来的命令，控制设备进行操作
- 组成
  - 与主机的接口：主机与设备间传递命令、状态 、数据
    - 硬件接口：PCIe、SATA、USB
  - 控制寄存器：1个或多个，控制设备操作
    - 写控制寄存器，命令设备执行指定的操作
    - 读控制寄存器，获得设备的状态
  - 数据缓冲区
    - 缓冲数据
    - 使用主机端和设备内的DRAM缓冲数据
    - 如果该缓冲区可以服务读请求，也将其视为数据缓存区

寻址：控制寄存器和设备数据缓冲区

- I/O端口： I/O地址空间（Port Mapped IO, PMIO）
  - 设备寄存器被映射到独立的地址空间
  - 设备寄存器使用端口号来表示其地址，一般为8位或16位的数值
  - I/O专用指令in/out（例如x86）：特权指令
  - 控制线：指示CPU发出的地址是内存空间还是I/O空间
  - 内存地址空间和I/O地址空间隔离
- 内存映射I/O （Memory Mapped IO, MMIO）
  - 统一地址空间，内存地址空间预留一部分给I/O设备内存和寄存器
  - 使用常规的访存指令集
  - 内存地址与I/O地址无重叠
  - 例子：x86 32位地址空间（0x0000 0000到0xFFFFF FFF）
    - 低端地址：0x0000 0000到0x0009 FFFF（640KB）通常用于传统I/O设备和BIOS。
    - 高端 地址：0xF000 0000到0xFFFF FFFF（256MB）通常用于PCI设备和其他现代I/O设备

寻址：控制寄存器和设备数据缓冲区

- 两者可以结合
  - 控制寄存器采用I/O端口寻址
  - 数据缓冲区采用内存映射I/O
- 好处
  - 高效：访问数据缓冲区不用专用指令，通过正常访存完成

内核缓冲区

- 为什么需要内核缓冲区
  - 生产者（应用）与消费者（IO设备）之间速度不匹配
  - 字符设备、块设备速度较慢，适配不同的数据传输速率
- 用作数据读缓存
  - 可以服务对同一数据的读请求
  - 减少实际访问设备的I/O操作

内容提要

- I/O 设备
  - 设备控制器与缓冲区
  - 寻址
- 数据传输
  - PIO, 中断, DMA
- 同步I/O与异步I/O
- 设备驱动

设备数据传输

- 数据传输
  - 初始化设备 + 数据传输
  - 初始化时间
    - CPU用于启动设备进行操作的时间
  - 传输带宽
    - 启动设备后数据传输的速率
    - Bytes/sec
  - 传输延迟
    - 传输一定粒度数据所需的时间（例如，4KB）
- 不同设备的数据传输
  - 字符设备
    - 对字节流传输的抽象，例如键盘、串口、打印机等
    - 逐个字符进行读写，字节粒度访问，以若干字节为传输粒度，顺序读写
  - 块设备
    - 以块为存储粒度和传输粒度，例如磁盘、SSD等
    - 按块寻址，整块读写，顺序/随机读写

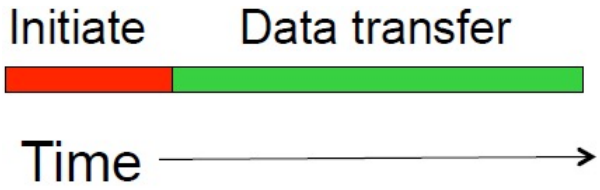

Device	Transfer rate
Keyboard	10Bytes/sec
Mouse	100Bytes/sec
…	…
10GE NIC	1.2GBytes/sec

数据传输方式

- PIO（Programmed I/O）
- 中断（Interrupt）
- DMA（Direct Memory Access）

PIO

- 例子：RS-232串口
- 简单的串行控制器
  - 状态寄存器：就绪、忙、…
  - 数据寄存器
- 输出数据时

  CPU：
  - 等待设备状态变为非“忙”
  - 写数据到数据寄存器
  - 通知设备“就绪”

  设备：
  - 等待直到状态变为“就绪”
  - 清除“就绪”标志，设置“忙”标志
  - 从数据寄存器中拿走数据
  - 清除“忙”标志

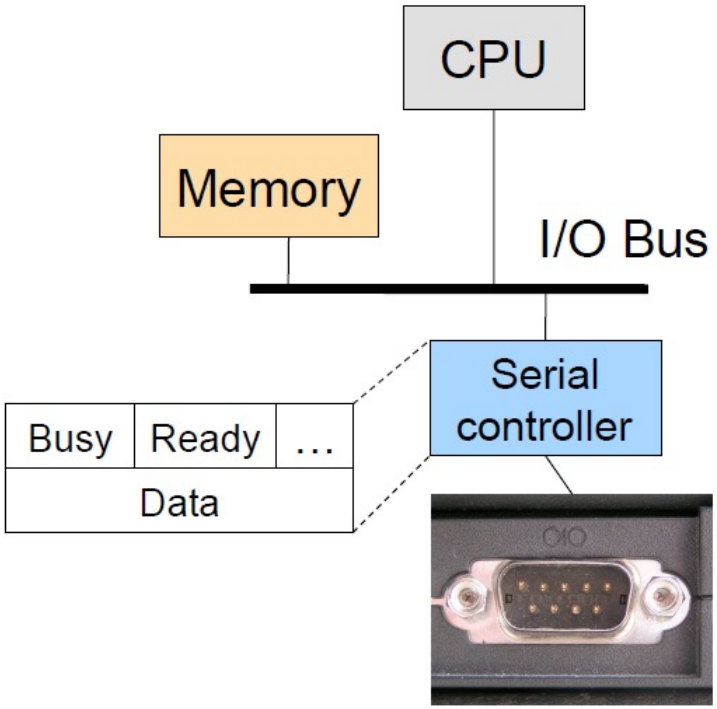

PIO的轮询 (Polling)

- CPU等待直到设备状态变为非“忙”
  - 轮询：不停地检查设备状态，“忙等”
- 好处
  - 实现简单
- 不足
  - 浪费CPU
- 例子
  - 如果一个设备的速度是100 ops/s，CPU需要等待10ms
  - 对于1GHz的CPU，意味着 1千万个CPU 时钟周期
- 改进：中断机制可避免CPU轮询

支持中断的设备

- 例子：鼠标
- 简单的鼠标控制器
  - 状态寄存器（完成、中断、…）
  - 数据寄存器（ΔX, ΔY, 按键）
- 输入数据时

  鼠标
  - 等待直到设备状态变为“完成”
  - 将ΔX, ΔY和按键的值保存到数据寄存器
  - 发中断

  CPU（中断处理）
  - 清除“完成”标志
  - 将ΔX, ΔY和按键的值读到内核缓冲区（内存）中
  - 置“完成”标志
  - 调用调度器

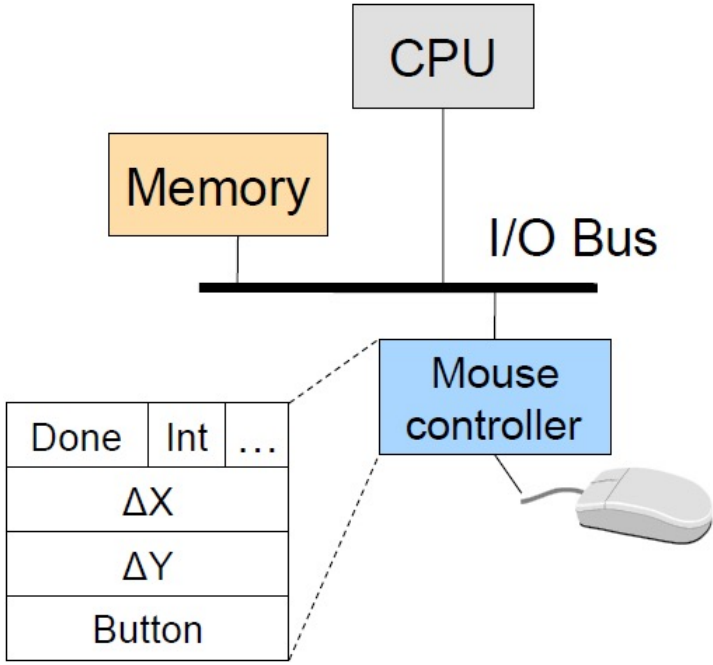

DMA (Direct Memory Access)

- 基于数据寄存器传输数据的不足
  - 数据寄存器满后，发送中断请求，CPU进行中断处理
  - 传输大量数据时，中断频繁，需要CPU频繁处理中断
- DMA
  - 以数据块为单位进行传输，由DMA控制器控制完成外设与主机间的数据传输
  - DMA需要地址连续的内核缓冲区
  - CPU在数据开始传输前设置DMA控制器
  - 数据传输结束后，DMA控制器发送中断给CPU，CPU进行处理
  - 减少占用CPU资源

DMA (Direct Memory Access)

- 例子：磁盘
- 一个简单的磁盘控制器
  - 状态寄存器（完成、中断、…）
  - DMA内存地址和字节数
  - DMA控制寄存器：命令、设备、传输模式及粒度
  - DMA数据缓冲区
- DMA写

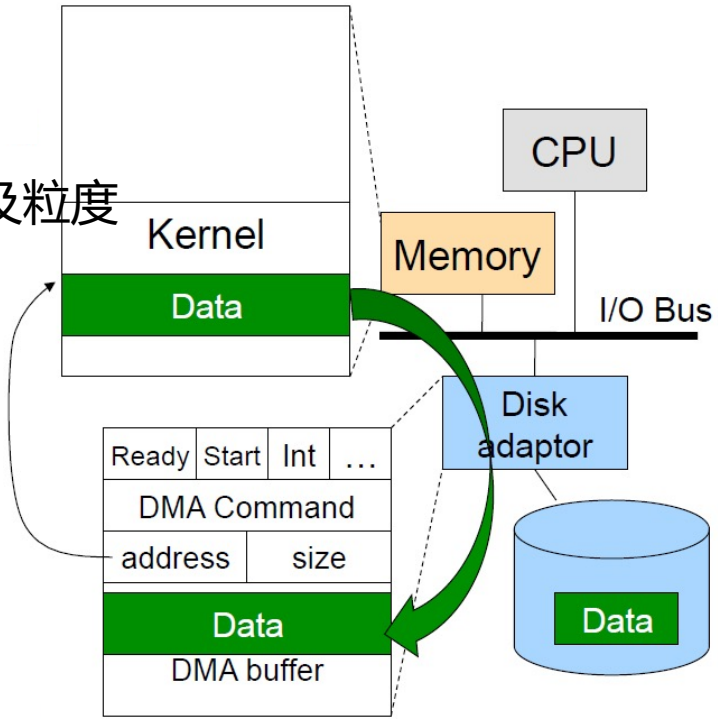

CPU：
  - 等待DMA设备状态为“就绪”
  - 清除“就绪”
  - 设置DMA命令为write，地址和大小
  - 设置“开始”
  - 阻塞当前的线程/进程

磁盘控制器：
  - DMA方式将数据传输到缓冲区，（count--; addr++）
  - 当count==0，发中断

CPU（中断处理）：
  - 将被该DMA阻塞的线程/进程加到就绪队列

磁盘：
  - 将数据从缓冲区写入磁盘

内容提要

- I/O 设备
  - 设备控制器与缓冲区
  - 寻址
- 数据传输
  - PIO, 中断, DMA
- 同步I/O与异步I/O
- 设备驱动

同步I/O与异步I/O

- 同步I/O
  - read( ) 和 write( )将阻塞用户进程，直到读写完成
  - 在一个进程做同步I/O时， OS调度另一个进程执行
- 异步I/O
  - aio_read( ) 和 aio_write( )不阻塞用户进程
  - 在I/O完成以前，用户进程可以做别的事
  - I/O完成将通知用户进程

异步I/O接口

POSIX P1003.4 异步I/O接口函数
（Solaris, AIX, Linux 2.6, …都支持）

- aio_read: 异步读
- aio_write: 异步写
- aio_fsync: 异步地将缓存脏块写回磁盘，并将errno设置为ENOSYS
- lio_listio: 提交一组I/O请求
- aio_return: 获取异步I/O操作的状态
- aio_error: 获取异步I/O错误状态
- aio_cancel: 取消异步读写请求
- aio_suspend: 挂起直到异步I/O操作完成

同步读

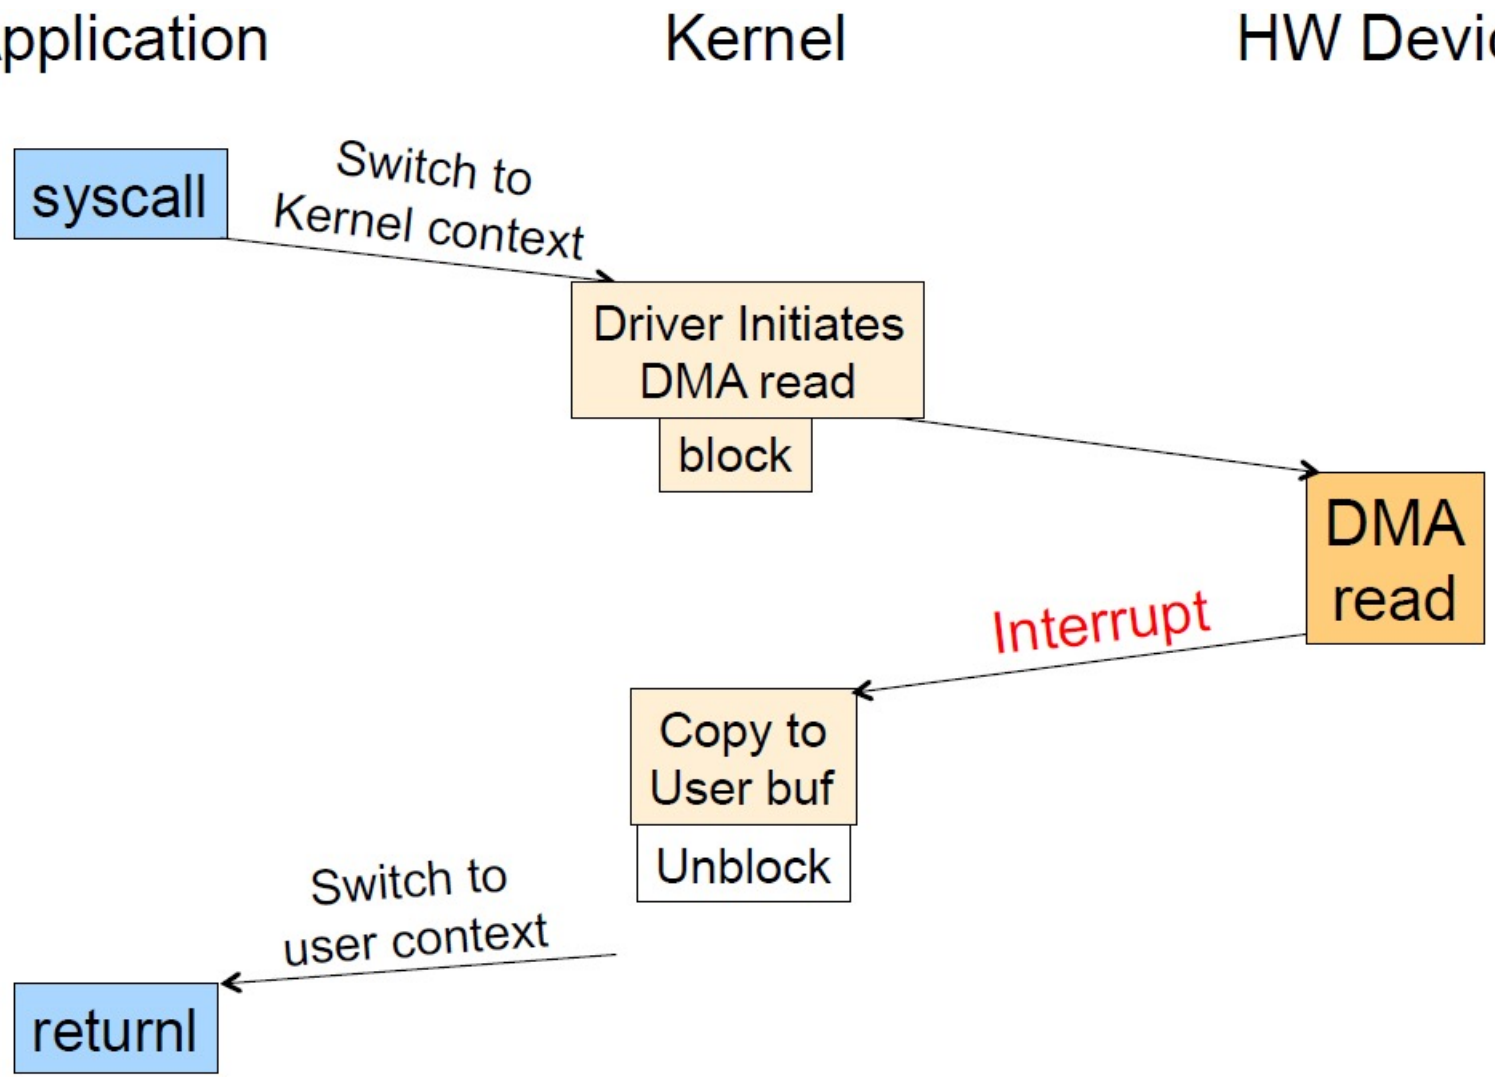
Application
Kernel
HW Device
syscall
Switch to
Kernel context
Driver Initiates
DMA read
block
DMA
read
Interrupt
Copy to
User buf
Unblock
Switch to
user context
returnl

同步读

- 用户进程P1调用**read( )**系统调用
- 系统调用代码检查正确性和缓存
- 如果需要进行I/O，会调用设备驱动程序
- 设备驱动程序为读数据分配一个buffer，并调度I/O请求
- 启动DMA进行读传输
- **阻塞**当前进程P1，**调度**另一个就绪的进程P2
- 设备控制器进行DMA读传输
- 传输完时，设备发送一个**中断**请求
- 中断处理程序**唤醒**被阻塞的用户进程P1（将P1加入就绪队列）
- 设备驱动检查结果（是否有错误），返回
- 将数据从内核buffer拷贝到用户buffer
- read系统调用返回到用户程序
- 用户进程继续执行

异步读

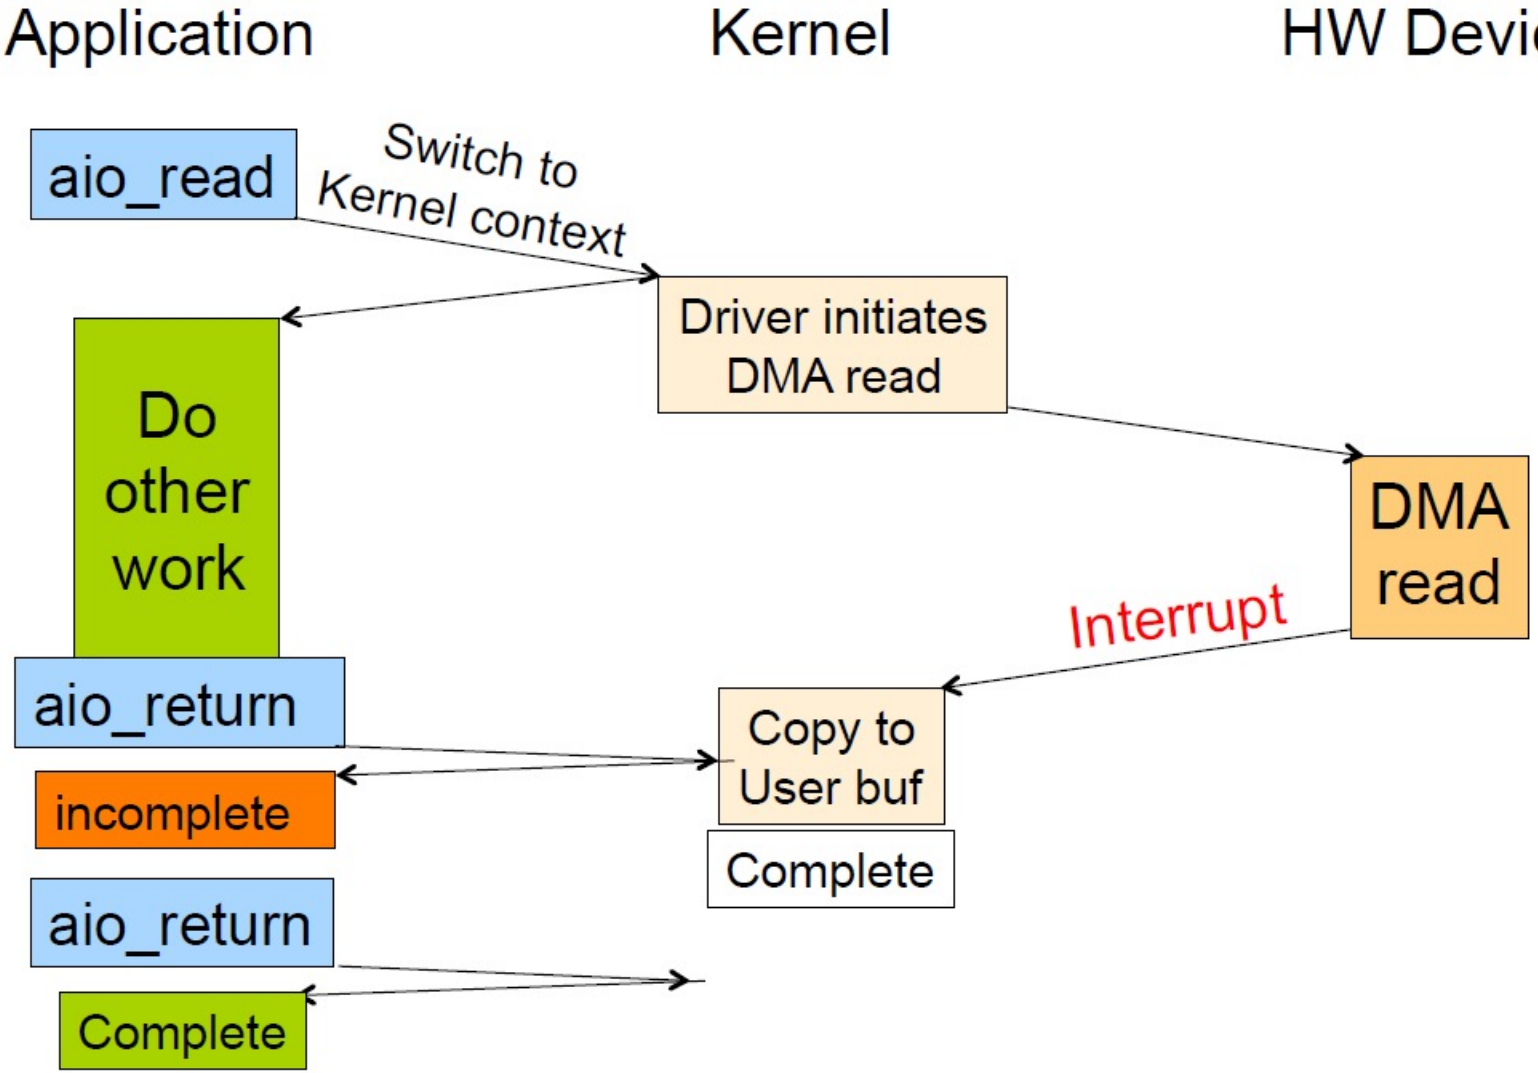
Application
Kernel
HW Device
aio_read
Switch to
Kernel context
Driver initiates
DMA read
Do
other
work
DMA
read
Interrupt
aio_return
Copy to
User buf
incomplete
Complete
aio_return
Complete

内容提要

- I/O 设备
  - 设备控制器与缓冲区
  - 寻址
- 数据传输
  - PIO, 中断, DMA
- 同步I/O与异步I/O
- 设备驱动

I/O软件栈

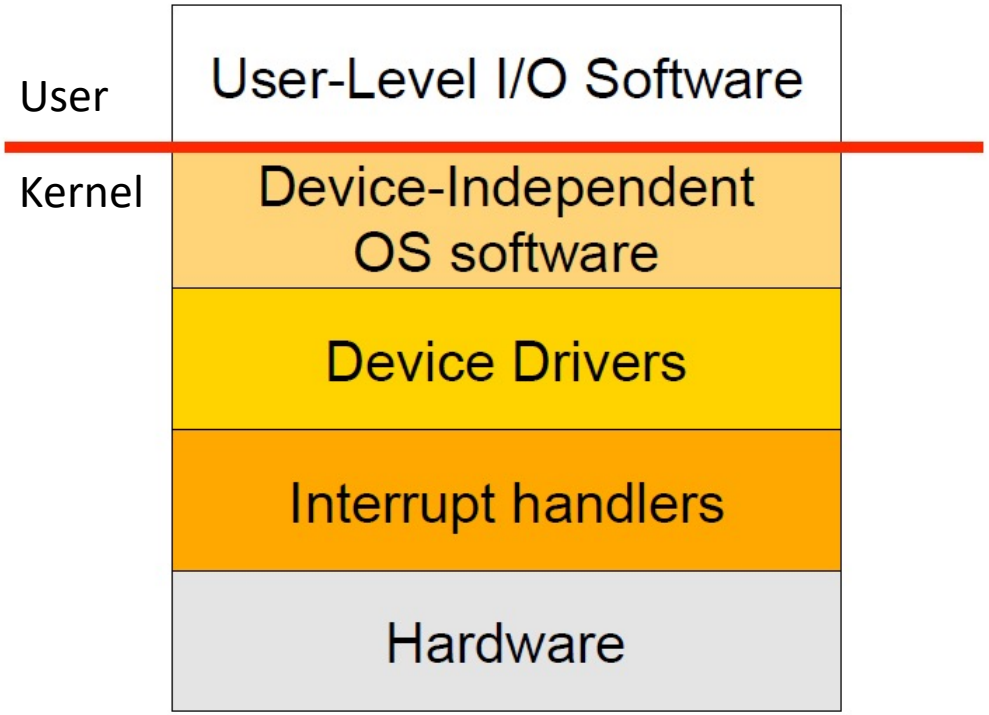
User
Kernel
User-Level I/O Software
Device-Independent OS software
Device Drivers
Interrupt handlers
Hardware

设备驱动

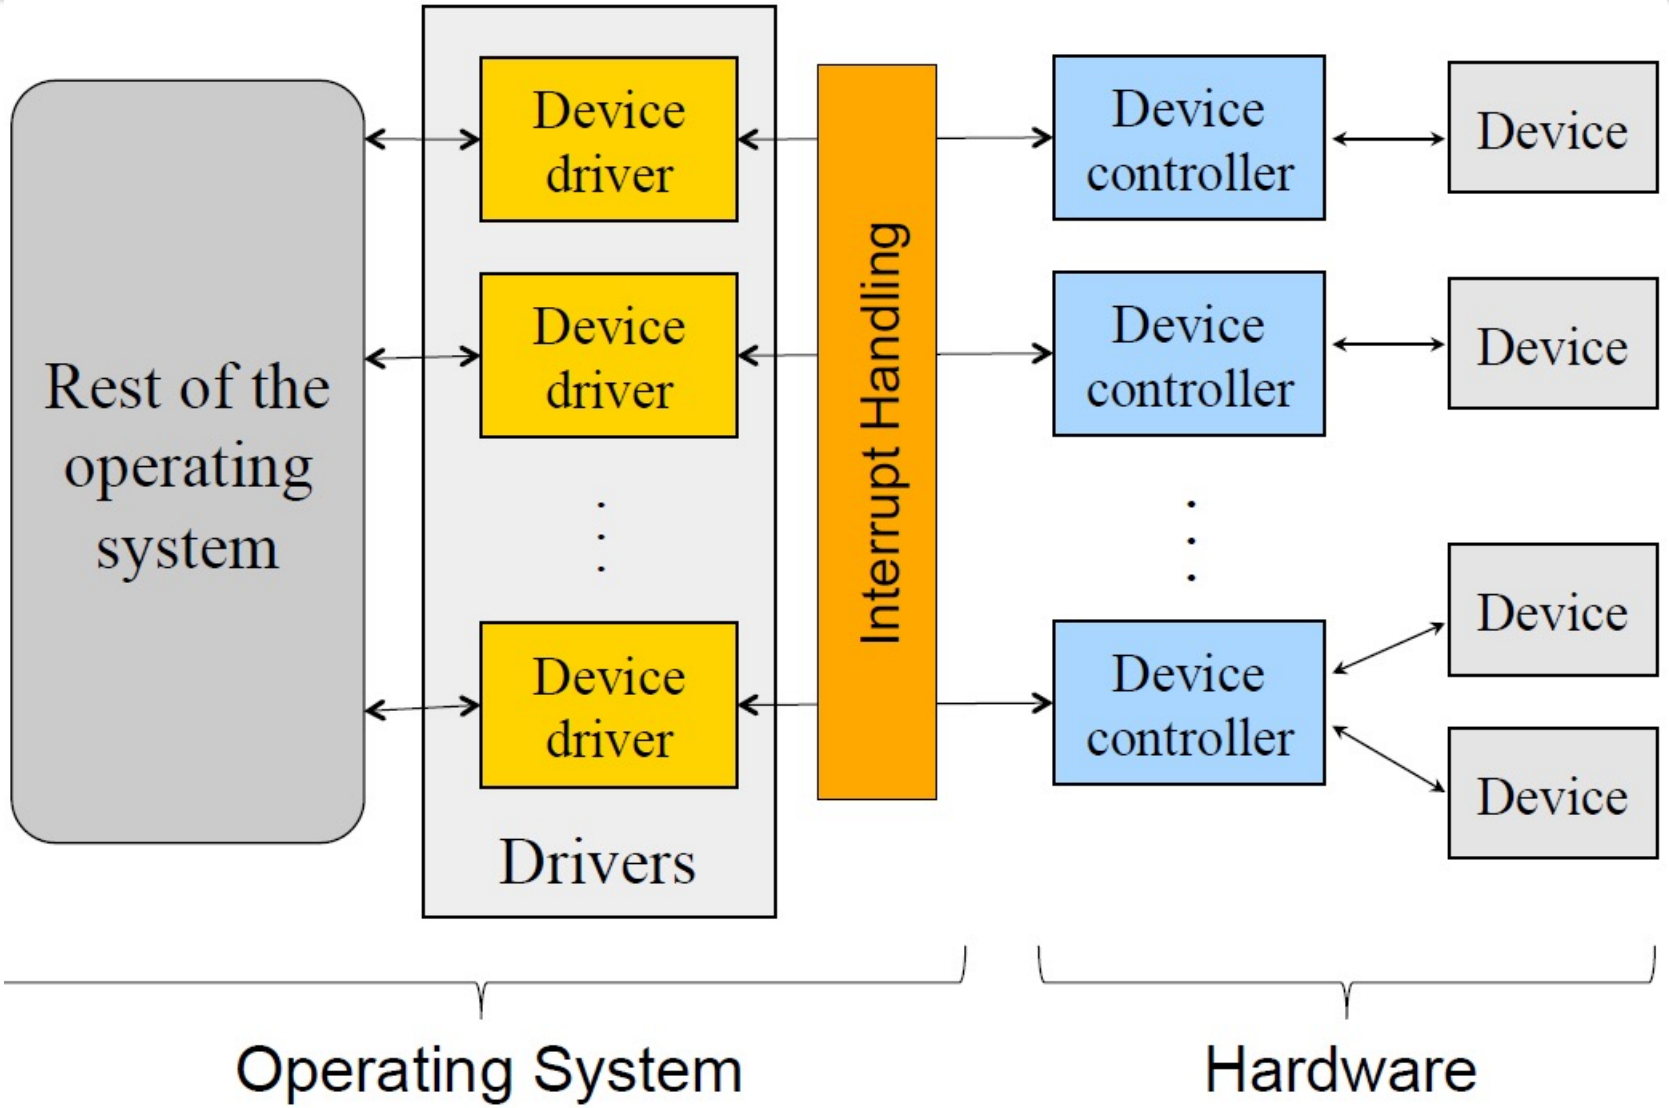
Rest of the operating system
Device driver
Device driver
Device driver
Drivers
Interrupt Handling
Device controller
Device controller
Device controller
Device
Device
Device
Device
Operating System
Hardware

设备驱动

- 给操作系统的其它模块提供操作设备的API
  - Init, Open, Close, Read, Write, …
- 与设备控制器交互
  - 与设备控制器交互以进行数据传输：命令、参数、数据
- 主要功能
  - 初始化设备
  - 解析OS发来的命令
  - 多个请求的调度
  - 管理数据传输
  - 接收和处理中断
  - 维护驱动与内核数据结构的完整性

设备驱动的主要流程

- 准备工作
  - 参数检查、请求格式转换
  - 设备状态检查：忙→请求入队列
  - 开设备或上电时执行
- 操纵设备
  - 将控制命令写入设备的控制寄存器
  - 检查设备状态：就绪→写下一命令
  - 直到设备完成所有命令
- 阻塞等待
  - 等待设备完成工作
  - 被中断唤醒
  - 有的设备不需要等待：如显示器
- 错误处理
  - 检查设备返回结果，如果返回错误，可能retry
- 返回调用者

设备驱动操作接口

- Init (deviceNumber)
  - 初始化硬件
- Open (deviceNumber)
  - 初始化驱动，并在内核中分配资源
- Close (deviceNumber)
  - 回收资源，关闭设备
- 设备驱动的类型
  - 字符设备：可变长度的数据传输
    - 几个字节，e.g. 鼠标，串口
  - 块设备：以固定大小的块为粒度的数据传输

设备驱动操作接口

- 字符设备接口
  - read (deviceNumber, bufferAddr, size)
    - 从字节流设备上读“size”字节数据
  - write (deviceNumber, bufferAddr, size)
    - 将“bufferAddr”中size字节数据写入字节流设备
- 块设备接口
  - read (deviceNumber, deviceAddr, bufferAddr)
    - 从设备传输1个块的数据到内存
  - write (deviceNumber, deviceAddr, bufferAddr)
    - 从内存传输1个块的数据到设备
  - seek (deviceNumber, deviceAddr)
    - 将磁头移动到指定块
    - 现在的设备磁头移动是控制器来控制，对设备驱动透明

示例：UNIX设备驱动接口

- init()
  - 初始化硬件
- start()
  - 开机时初始化，需要系统服务
- halt()
  - 在系统关机前要调用
- open(dev, flag, id) 和 close(dev, flag, id)
  - 初始化资源和释放资源
- intr(vector)
  - 在发生硬件中断时由内核调用
- read(…) 和 write(…)
  - 数据传输
- poll(pri)
  - 内核每秒调用25次~100次
- ioctl(dev, cmd, arg, mode)
  - 特殊请求处理

设备驱动安装

- 静态安装设备驱动
  - 将设备驱动直接编译进内核，系统启动后可以直接调用
  - 新设备的使用需要重启OS
  - 设备驱动修改效率不高，需要重新编译内核

- 动态挂载设备驱动
  - 将驱动动态加载进内核空间
  - 不需要重启，而是采用间接指针
  - 安装入口点，维护相关的数据结构
  - 初始化设备驱动

动态绑定设备驱动

- 间接指针
  - 设备入口点表：
    所有设备的入口点
- 加载设备驱动
  - 分配内核空间
  - 加载存储驱动代码
  - 与入口点关联
- 删除设备驱动
  - 删除入口点
  - 释放内核空间

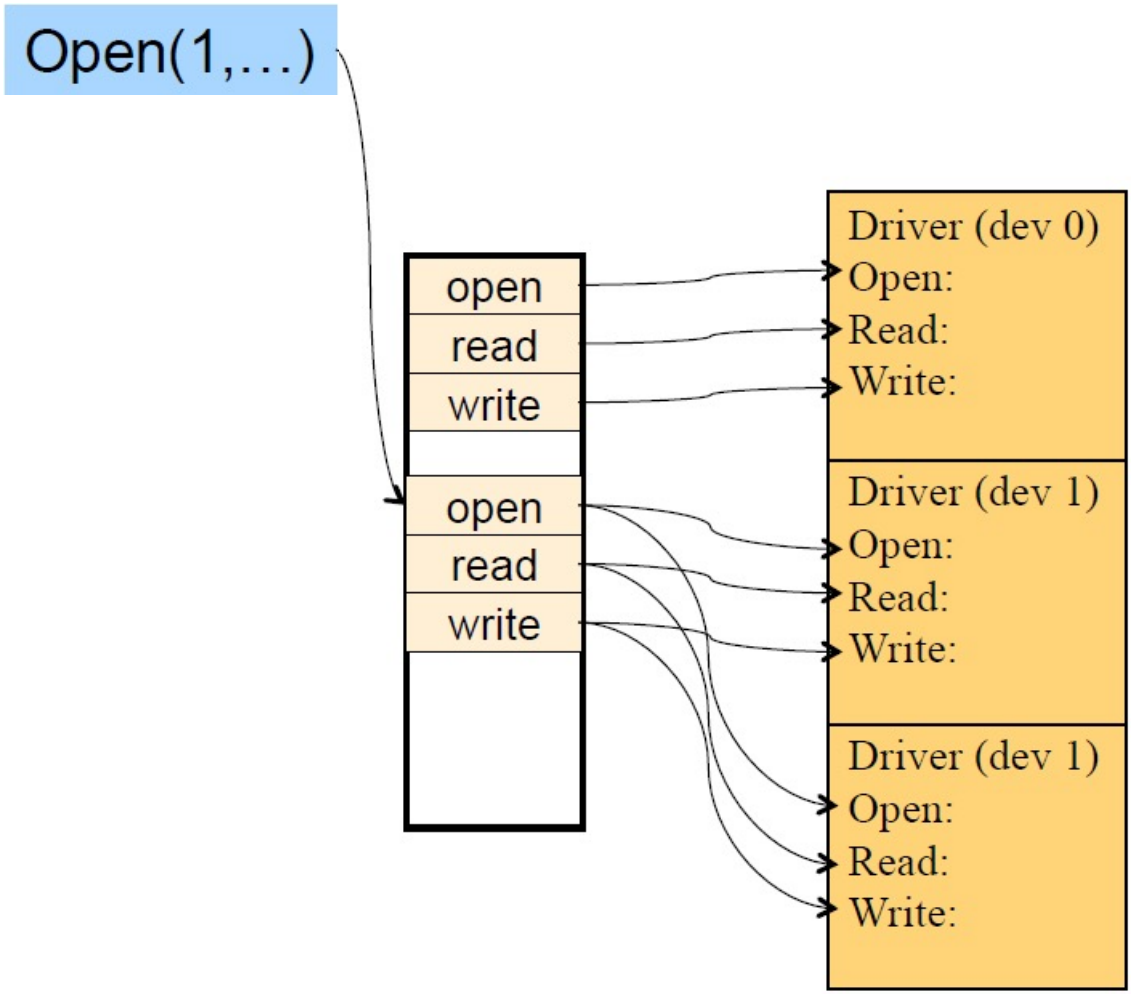

设备驱动的利与弊

- 灵活性：
  - 用户可以下载和安装设备驱动
  - 灵活接入不同硬件设备
- 安全隐患
  - 设备驱动运行于内核态
  - 有bug的设备驱动会导致内核崩溃，或者引入安全漏洞
- 如何让设备驱动更安全
  - 为设备驱动构建状态机模型进行形式化验证
- 用户态驱动：面向高速设备，提升性能

总结

- I/O设备
  - PIO简单、但不高效
  - 中断机制支持CPU与I/O重叠
  - DMA比基于数据寄存器的中断更加高效，减少CPU在传输过程的介入
- 设备驱动
  - 直接操纵设备的程序代码
  - OS代码中大量设备驱动代码
  - 设备驱动引入安全漏洞，解决设备驱动的安全隐患是一个open problem
  - 用户态驱动的发展
- 异步I/O
  - 异步I/O允许用户程序的计算与I/O重叠

附录：表示大小的单位

单位名称	缩写	10^n	缩写	2^n	英文 Short scale
yotta	Y	10^{24}	Yi	2^{80}	septillion
zetta	Z	10^{21}	Zi	2^{70}	sextillion
exa	E	10^{18}	Ei	2^{60}	quintillion
peta	P	10^{15}	Pi	2^{50}	quadrillion
tera	T	10^{12}	Ti	2^{40}	trillion
giga	G	10^{9}	Gi	2^{30}	billion
mega	M	10^{6}	Mi	2^{20}	million
kilo	K	10^{3}	Ki	2^{10}	hundred
hecto	h	10^{2}			ten
deca	da	10^{1}			one

单位名称	缩写	10^n	英文 Short scale
deci	d (分)	10^{-1}	tenth
centi	c (厘)	10^{-2}	hundredth
milli	m (毫)	10^{-3}	thousandth
micro	μ (微)	10^{-6}	millionth
nano	n (纳)	10^{-9}	billionth
pico	p (皮)	10^{-12}	trillionth
femto	f	10^{-15}	quadrillionth
atto	a	10^{-18}	quintillionth
zepto	z	10^{-21}	sextillionth
yocto	y	10^{-24}	septillionth

GB=10^9 Bytes vs. GiB=2^{30} Bytes，类似地，KB vs. KiB，MB vs. MiB，…