Solid State Drive

中国科学院大学计算机学院

2025-12-22

内容提要

- 固态硬盘SSD
  - 闪存组织
  - SSD FTL机制
    - 地址映射
    - 磨损均衡

回顾：磁盘的结构

- 盘片：一组
  - 按一定速率旋转
- 磁道 (Track)
  - 位于盘片表面的同心圆
  - 用于记录数据的磁介质
  - bit沿着每条磁道顺序排列
- 扇区 (Sector)
  - 磁道划分为固定大小的单元
    一般为512字节
- 磁头：一组
  - 用于读写磁道上的数据
- 磁臂：一组
  - 用于移动磁头（多个）

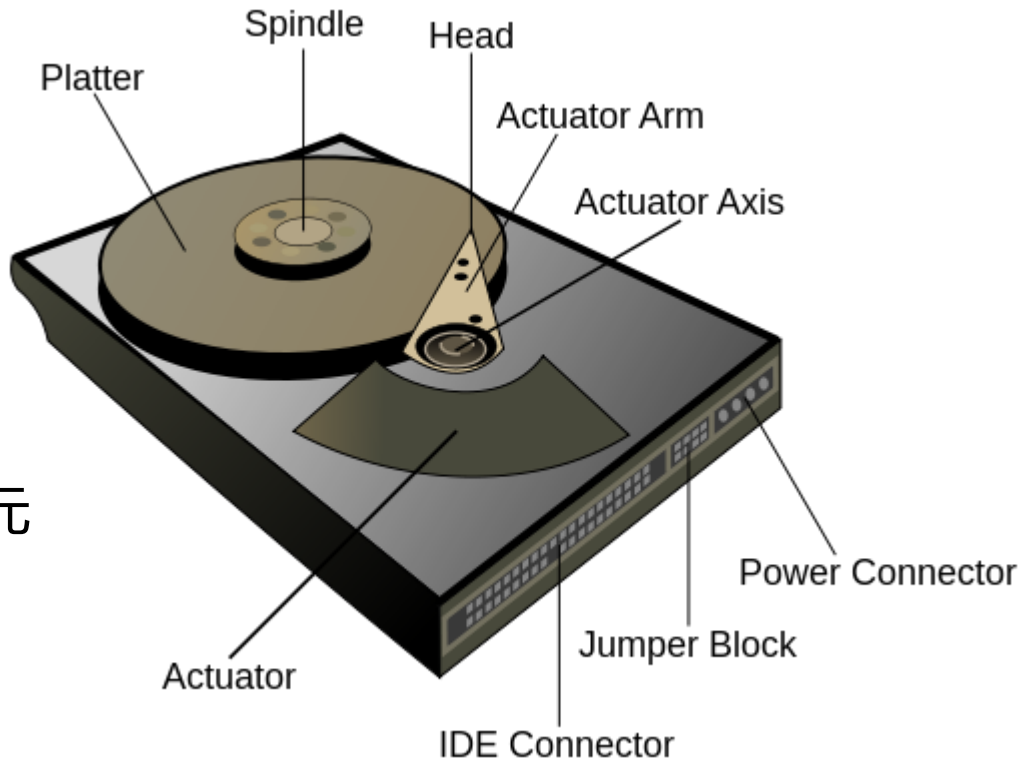

闪存（Flash memory）

- 1984: NOR flash, 日本东芝公司, Fujio Masuoka
- 1987: NAND flash,日本东芝公司
- 全电子器件，无机械部件
- 非易失性存储
- 1992：SSD原型，SandDisk

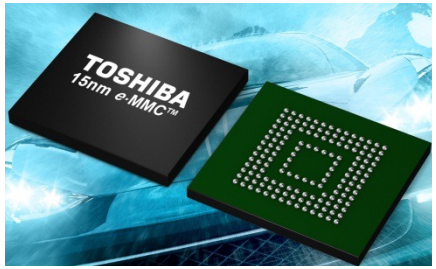

NOR闪存 vs. NAND闪存

- NOR是字节寻址，NAND是页寻址
- NOR读延迟是比NAND低100x
- NOR的擦除时间比NAND高300x
- NOR用于实现 ROM，存可执行代码
- NAND用于大容量持久化存储设备

闪存

- 信息存储方式
  - SLC: 1 bit/cell, 2个值：0/1
  - MLC: 2 bits/cell, 4个值：00/01/10/11
  - TLC: 3 bits/cell, 8个值
  - QLC: 4 bits/cell, 16个值
- 对应存储单元的不同电压值

NAND闪存组织

- Flash package
  - 包含1,2,4,8,16个Die
- Die
  - 包含1,2,4个Plane
- Plane
  - 包含数百到数千个块
- **块** (Block/Erase Block)
  - 擦除块
  - 包含几十到几百个页
- **页** (Page)
  - 包含很多cell

NAND闪存组织

- Flash package
  - 包含1,2,4,8,16个Die
- Die
  - 包含1,2,4个Plane
- Plane
  - 包含数百到数千个块
- **块** (Block/Erase Block)
  - 擦除块
  - 包含几十到几百个页
- **页** (Page)
  - 包含很多cell

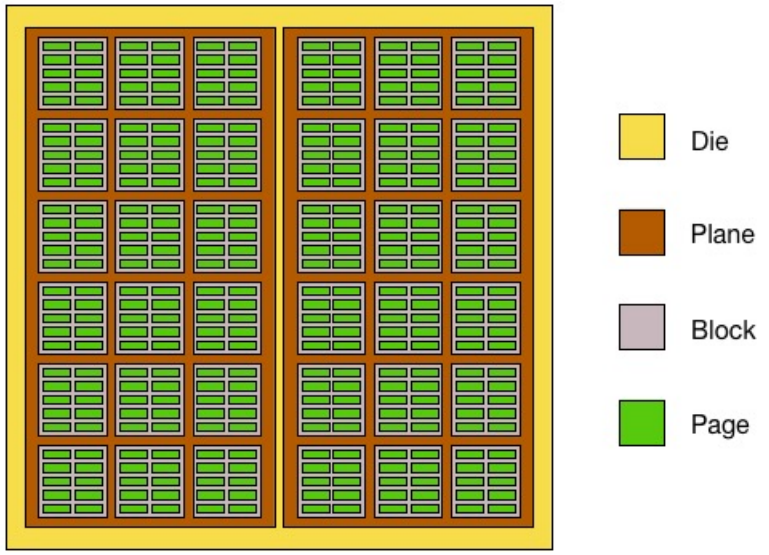

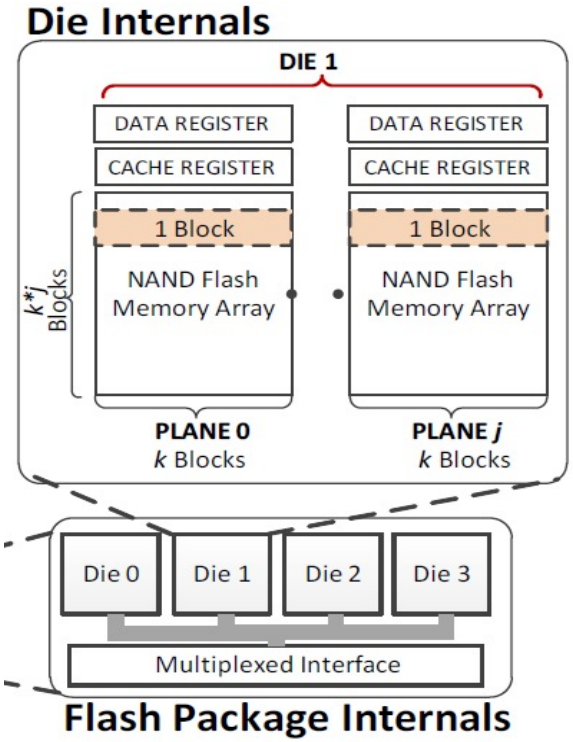

闪存组织

- 页
  - 由数据区与OOB（Out Of Band）区构成
  - 数据区用于存储实际数据
  - OOB区用于记录
    - ECC
    - 状态信息：Erased/Valid/Invalid
    - Logic page number
  - 页大小
    - SLC通常2KB~8KB，TLC通常4KB~16KB
  - 64+页/块
  - 块大小
    - SLC通常128KB、256KB…
    - TLC通常2MB，4MB，8MB…

闪存的操作接口

- Read, Erase, Program (写)
- 读：read a page
  - 读的粒度是页
  - 读很快，读延迟在几十微秒 (us)
  - 读延迟与位置无关，也与上一次读的位置无关 (和磁盘不同)
- 擦除：erase a block
  - 把整个块写成全1
  - 擦除的粒度是块，必须整块擦除
  - 很慢：擦除时间为几个毫秒 (ms)
  - 需软件把块内有效数据拷贝到其它地方
- 写：program a page
  - 擦除后才能写，因为写只能把1变成0
  - 写的粒度是页
  - 写比读慢，比擦除快，写延迟在几百微秒 (us)

页的状态

Invalid, Erased, Valid

- 初始状态为Invalid
- 擦除：块内所有页的状态变为Erased
- 写
  - 只能写状态为Erased的页
  - 写完成，页状态变为Valid
- 读：不改变页的状态

闪存的性能和可靠性

- 性能
  - 写延迟比读高10倍以上
  - 擦除很慢：与磁盘访问延迟相当
  - 延迟随密度增加而增长
- 可靠性
  - 磨损
    - 擦写次数有上限，随密度增加而减少

Device	Read (µs)	Write (µs)	Erase (ms)	P/E Cycles
SLC	25	200-300	1.5-2	100,000
MLC	50	600-900	~3	10,000
TLC	~75	~900-1350	~4.5	1,000
QLC				200

闪存特性：

1. 读延迟很低：随机读的性能远优于磁盘
2. 写慢：必须先擦除再写，ms级 ~ 相当于磁盘写
3. 磨损：每个块擦写次数有上限

基于闪存的SSD

- 用很多闪存芯片（package）来构成一个持久化存储设备

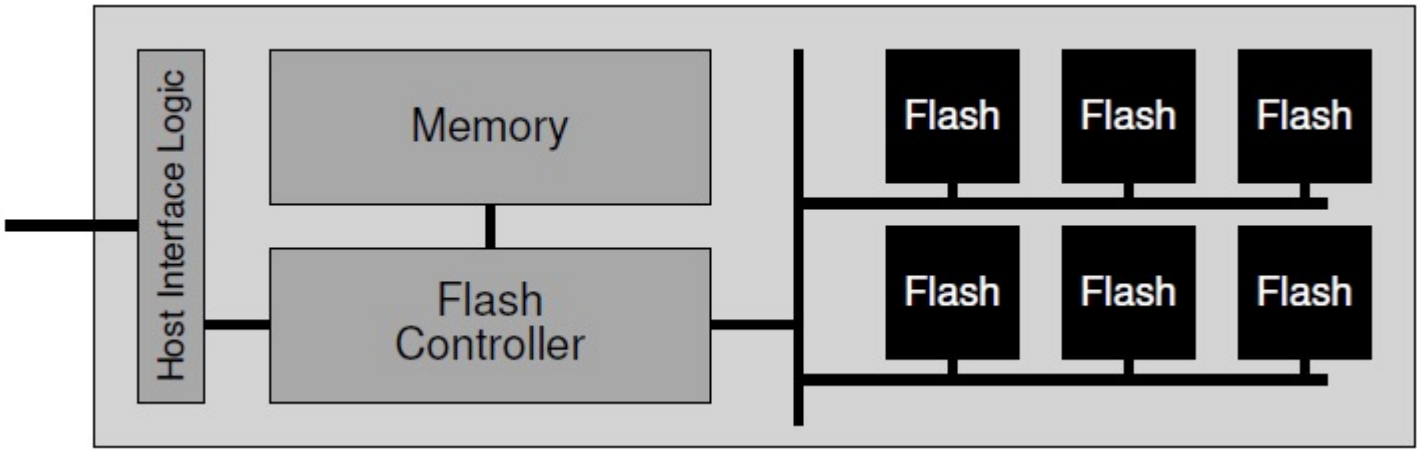

- 多个闪存芯片：并行I/O，提高 I/O性能
- 与主机的接口：提供标准块设备接口
- 数据缓存和缓冲：SRAM/DRAM
- 闪存控制器（硬件）和FTL（固件）：控制逻辑
  - 主机命令转换成闪存命令 (Read/Erase/Program)
  - 逻辑块地址转换成闪存的物理地址 (页/块)
  - 缓存替换

最简单的FTL：直接映射

- Direct mapping
  - 逻辑页的第N页固定地、直接映射到物理页的第N页
- 读操作容易：读逻辑第k页
  - 读物理第k页
- 写操作麻烦：覆盖写逻辑第k页
  - 第k页所在闪存块 (记为B0)
  - 把B0整个块读出来
  - 把B0整个块擦除
  - B0中的旧页和新的第k页：以顺序方式一页一页再写入B0
- 缺陷：写性能极差
  - 每覆盖写一个页，要读整个块、擦除整个块、写整个块
  - 写放大

FTL改进: 异地更新

- 核心思想：异地更新 (out-of-place update)
  - 不再执行原地更新
  - 每次写页，写到一个新位置（新的物理页地址）
- 页级映射
  - 映射表： LPN → 物理页地址PPN, 页级映射表
- 写一个逻辑页k
  - 寻找一个空闲页p（例如当前擦除块中下一个空闲页p）
  - 在映射表中记录: 逻辑页 k→物理页 p
- 读一个逻辑页k
  - 查映射表，获得逻辑页k对应的物理页地址p
  - 读物理页p

页级映射

例子：依次写逻辑页100, 101, 2000和2001 (a1, a2, b1, b2)

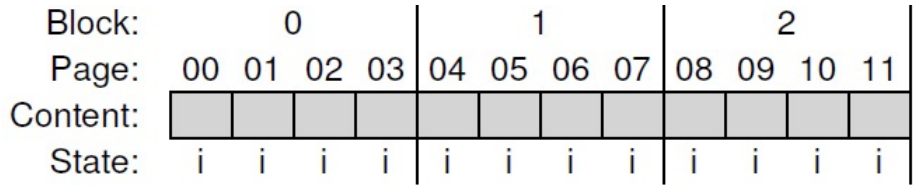

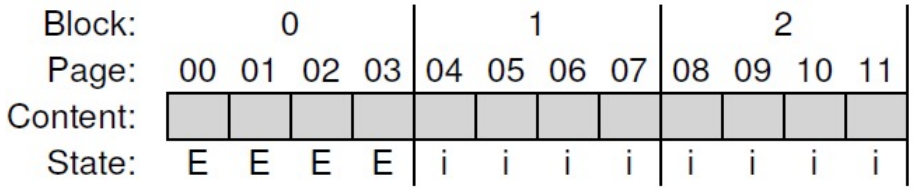

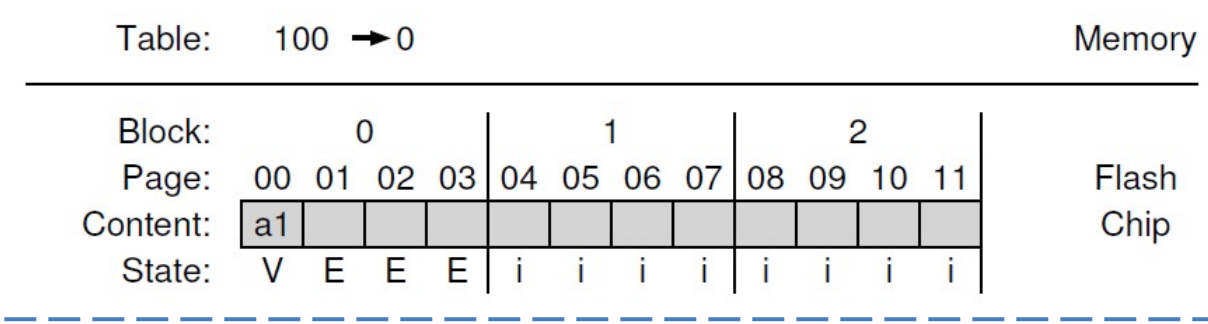

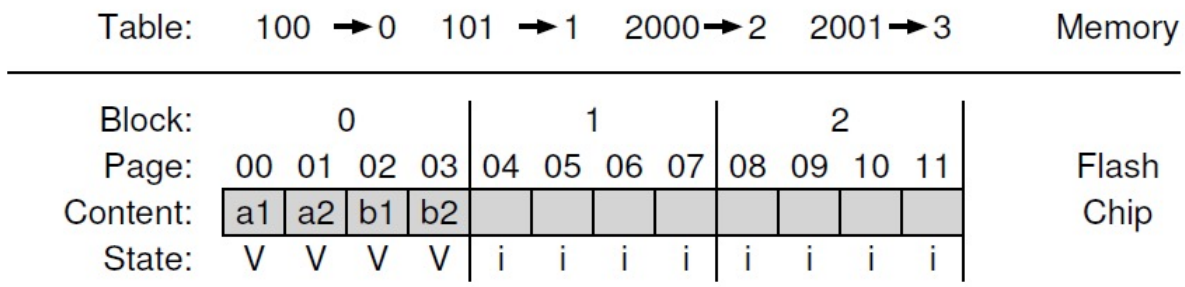

异地更新 + 页级映射

- 页级映射表：LPN → PPN
  - 整个放在内存中
  - 持久化：利用页的OOB区来保存反向映射关系，即PPN和LPN的映射关系
  - 随着写页而被写到闪存
  - 掉电或重启，扫描OOB区恢复映射表
- 优点
  - 性能好：减少写放大
  - 可靠性好：映射关系被自动写入闪存
- 问题
  - 覆盖写产生垃圾页
    - 每次写到新位置，导致原先页的内容无效
  - 内存开销大
    - 映射表全部放内存
    - 映射表的大小与SSD容量成正比

垃圾页 (garbage page)

例子：依次写逻辑页100, 101, 2000和2001 (a1, a2, b1, b2)

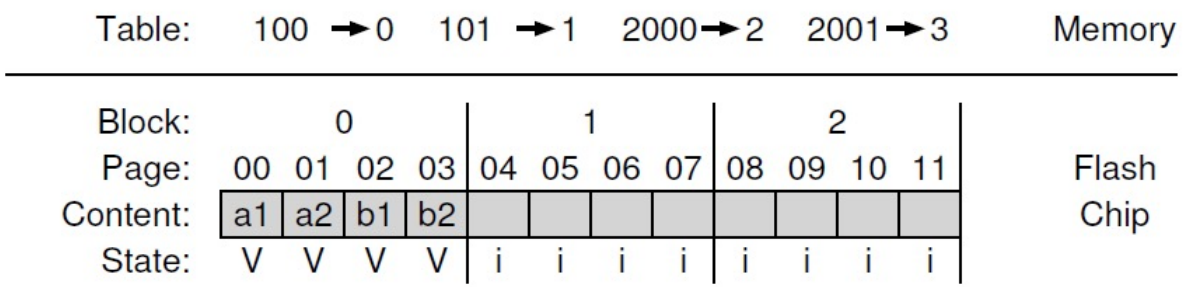

再写逻辑页100和101 (c1, c2)

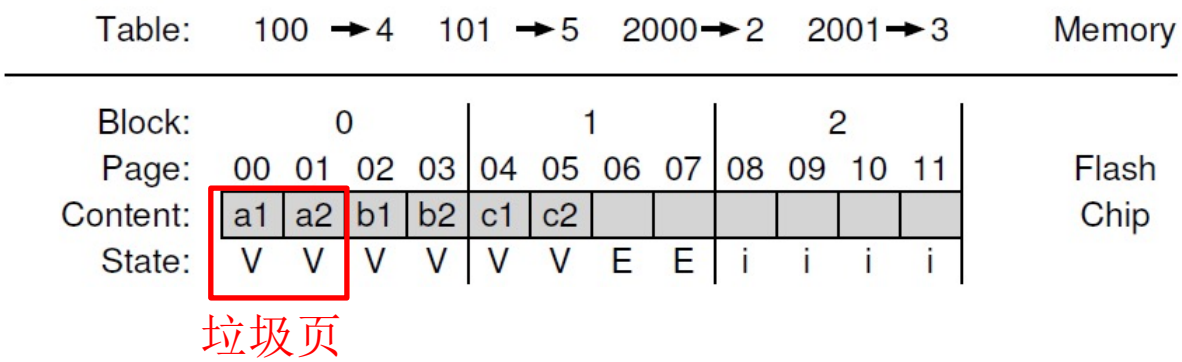

垃圾回收（Garbage Collection）

- 思想
  - 选择一个含垃圾页的擦除块
  - 把其中的有效页拷贝到其他擦除块中 (先读再重写)
  - 回收整个擦除块，并把它擦除
- 如何判断有效页？
  - 每个物理页记录它对应的逻辑页地址 (OOB区)
  - 查映射表, 如果映射表记录的PPN == 该逻辑页，是有效页

写LPN顺序： 100 101 2000 2001 100 101

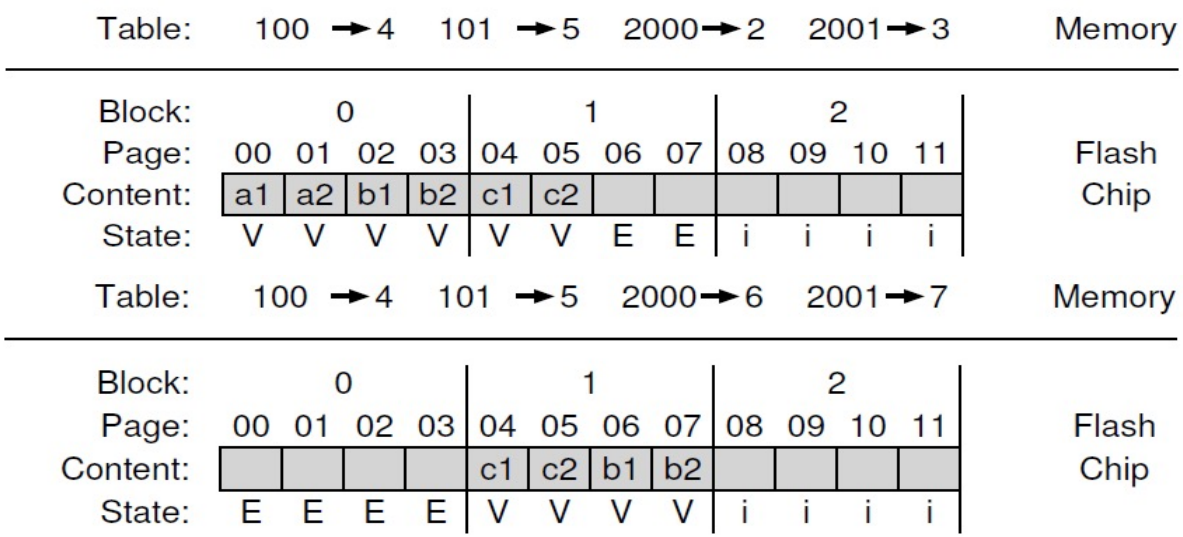

垃圾回收后

垃圾回收

- 问题：开销非常大
  - 有效页需要拷贝：先读再重写
  - 开销与有效页所占的比例成正比

- 解决办法：超配（over-provisioning）
  - 实际物理空间比用户所见空间更大：多15%~45%
    - 例如，用户看到100GB的SSD, 实际上内部是120GB
    - GC时将数据写入over-provisioning space，减少对性能的影响
  - GC一般在SSD后台执行，尽量在设备不忙时执行，但受限于空闲页数量
    - 空闲页不足时，即使设备忙也要开始执行GC

块级映射：block-level mapping

- 块级映射
  - 逻辑地址空间划分为chunk，chunk size=擦除块size
  - 映射表：chunk# → 擦除块地址PBN
- 读一个逻辑页
  - 逻辑页地址 = chunk# || 偏移
  - 用chunk#查映射表，获得对应的擦除块地址PBN
  - 物理页地址 = PBN || 偏移

例：依次写逻辑页2000, 2001, 2002, 2003 (a, b, c, d)

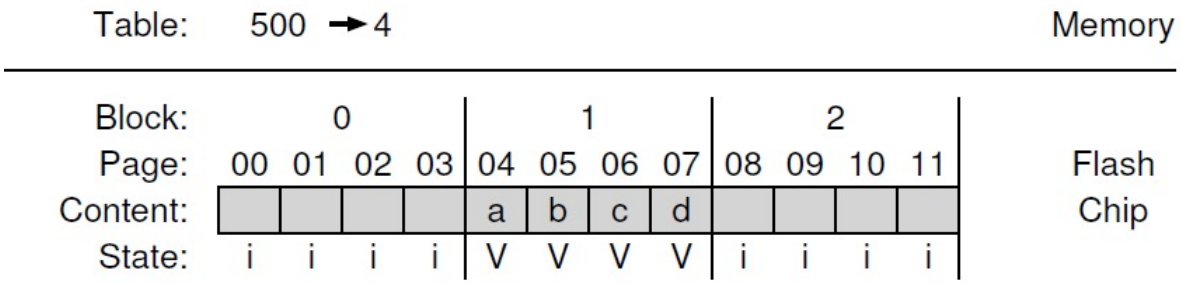

假设一个chunk有4个页，逻辑页2000对应的chunk#为500，将chunk#500映射到擦除块1（起始物理页号为4）

块级映射：block-level mapping

- 问题：小写性能差
  - 写粒度小于擦除块：拷贝有效页 (读 & 写), 导致写放大
  - 小写很常见：擦除块通常较大 (大于256KB)

例：依次写逻辑页2000, 2001, 2002, 2003 (a, b, c, d)

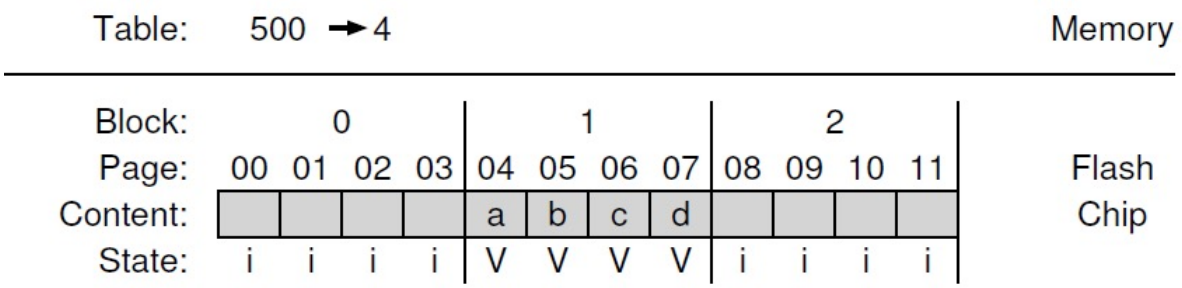

再写逻辑页2002 (c')

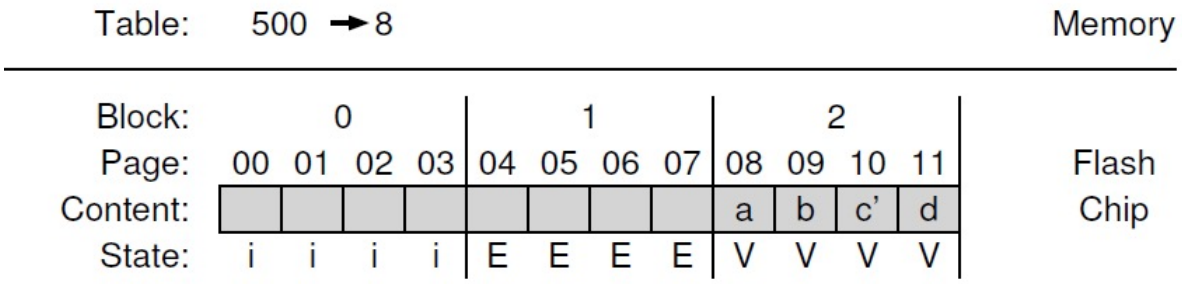

混合映射：hybrid mapping

- 思想
  - 将擦除块划分为两类：数据块和日志块
  - 写逻辑页时都写入日志块
  - 数据块采用块级映射，数据映射表
  - 日志块采用页级映射，日志映射表
  - 适当的时候把日志块合并为数据块

- 读一个逻辑页
  - 先查日志映射表，按页级映射的方法
  - 如果没找到，再查数据映射表，按块级映射的方法

混合映射：hybrid mapping

例：当前逻辑页1000, 1001, 1002, 1003中数据分别为a,b,c,d

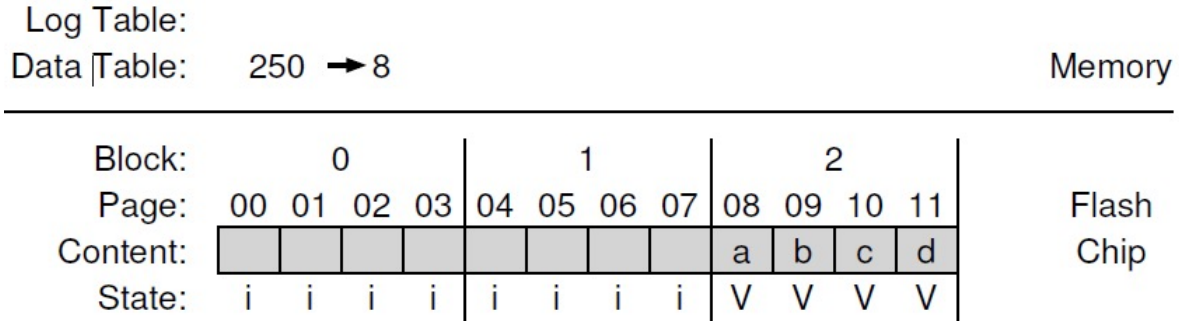

依次写逻辑页1000, 1001, 1002, 1003 (a', b', c', d')

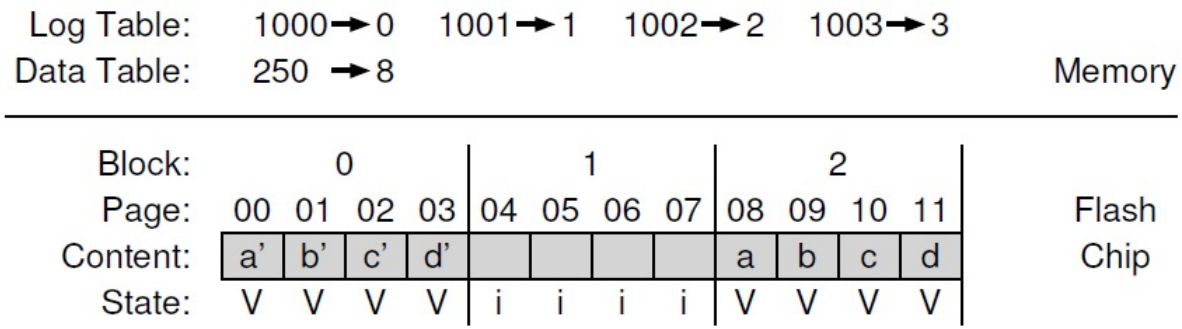

混合映射：hybrid mapping

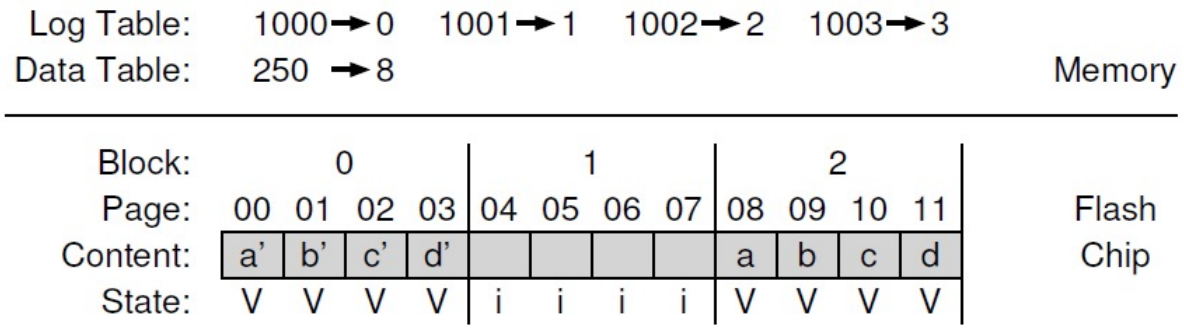

- Switch merge
  - 直接把日志块转成数据块: 前提是整个日志块的页序与原数据块中的页序一致
  - 把原来的数据块回收擦除
  - 优点：开销低，只修改映射表信息，无数据拷贝

合并后

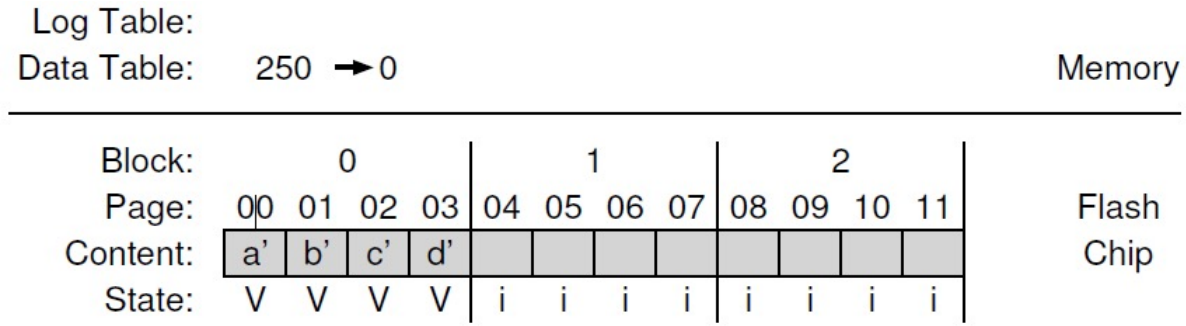

混合映射：hybrid mapping

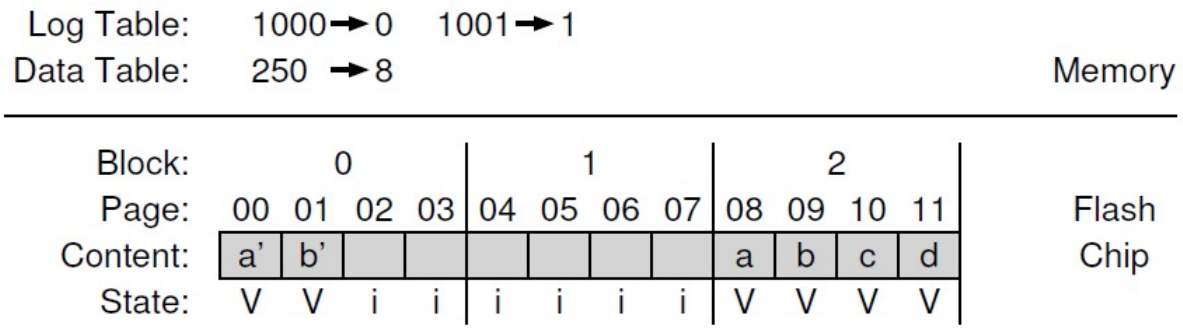

- Partial merge
  - 把数据块中有效页拷贝到日志块：日志块中页序与原数据块中的页序一致
  - 把日志块转成数据块，把原来的数据块回收擦除
  - 有数据拷贝开销

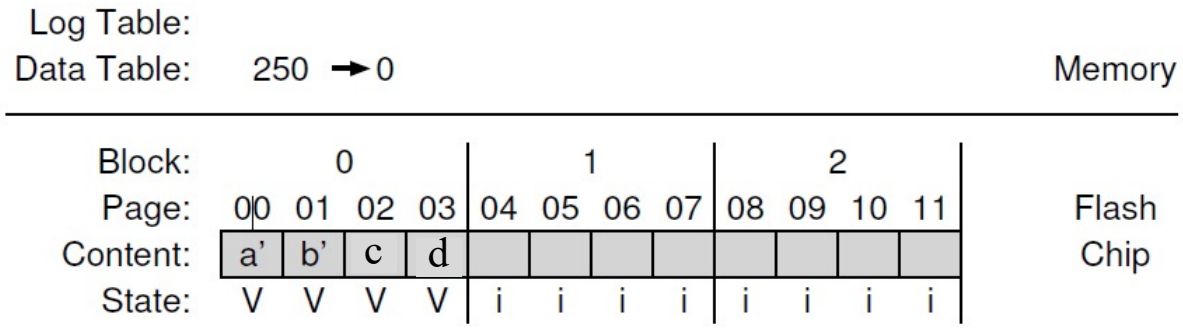

合并后

混合映射：hybrid mapping

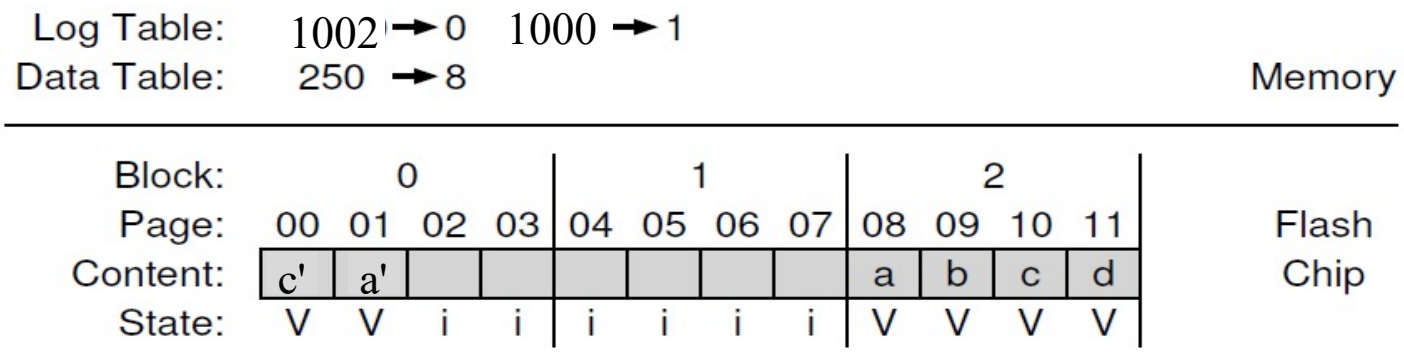

- Full merge
  - 分配一个新的日志块，从数据块和日志块分别拷贝有效页到新日志块
  - 把新日志块转成数据块
  - 把原来的数据块和日志块都回收擦除
  - 开销很大：需要拷贝整个物理块的数据（读 & 写）

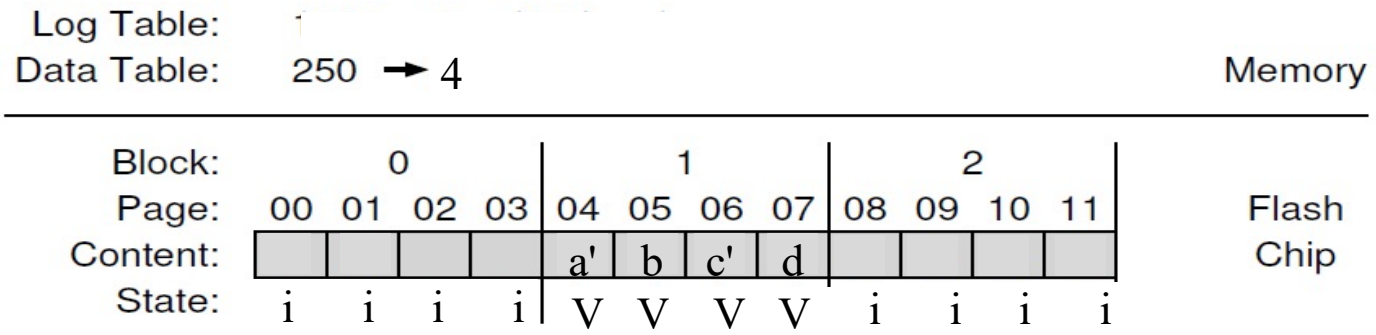

磨损均衡

- 目标
  - 让所有块被擦除的次数近似
- 动态磨损均衡
  - 每次写时，选择擦除次数较少或最少的空闲块
  - 局限性：不同数据的修改频率不同
    - 例子：只写一次的数据（static data），很少写的数据（cold data)
- 静态磨损均衡
  - 动态磨损均衡主要考虑擦除次数，不考虑不会被回收的物理块，例如长时间不被修改的物理块（写冷块）
  - 不再被写，不再有磨损
  - 解决办法：FTL定期重写冷块，将其写入磨损较多的块

总结

- 闪存的特性
  - 读延迟很低：读性能远优于磁盘
  - 写慢，擦除慢（ms级）：必须先擦除再写
  - 磨损：每个块擦写次数有上限
- SSD FTL主要功能